

Estudio comparativo de modelos de aprendizaje automático para la predicción de abandono de clientes en telecomunicaciones

Sandy Dahiana Ruiz Higueta

Facultad de Ingeniería

Universidad de Antioquia

Turbo, Colombia

sandy.ruizh@udea.edu.co

Abstract—La predicción de abandono de clientes (*customer churn*) es un problema crítico en la industria de las telecomunicaciones debido a su impacto en la retención de ingresos. En este trabajo se aborda este problema mediante técnicas de aprendizaje automático bajo un enfoque de clasificación supervisada, utilizando el dataset *Telco Customer Churn*. Se realiza un proceso de preprocesamiento que incluye codificación de variables, normalización y tratamiento de datos faltantes. Posteriormente se comparan múltiples modelos, incluyendo *regresión logística*, *KNN*, *máquinas de soporte vectorial*, *métodos de ensamblado* y *redes neuronales*. La evaluación se realiza mediante validación cruzada empleando métricas como *accuracy*, *precision*, *recall*, *F1-Score* y *ROC-AUC*. Los resultados evidencian que los modelos de ensamblado presentan el mejor desempeño.

cliente abandone el servicio a partir de variables demográficas, de uso y facturación.

En la literatura se observa una tendencia clara hacia la comparación de múltiples modelos, incluyendo enfoques tradicionales, métodos de ensamblado y redes neuronales. En el trabajo de Rabih et al. [1], se propone el uso de una red neuronal artificial tipo Multilayer Perceptron (**MLP**), comparada con modelos como Logistic Regression, Decision Tree, Random Forest, Support Vector Machine y Naive Bayes. La validación se realiza mediante partición train/test (80/20), utilizando métricas como *accuracy*, *precision*, *recall* y *F1-Score* definida como:

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (1)$$

I. INTRODUCCIÓN

En la industria de telecomunicaciones, la retención de clientes es un aspecto fundamental debido al impacto de abandono (*customer churn*) en los ingresos y la sostenibilidad de las empresas. La alta competencia en el sector hace necesario identificar de manera temprana a los clientes con mayor probabilidad de abandonar el servicio.

En este contexto las técnicas de aprendizaje automático permiten modelar patrones complejos a partir de datos históricos y mejorar la capacidad de predicción frente a enfoques tradicionales. El problema de abandono se plantea como una tarea de clasificación supervisada, donde se busca predecir si un cliente abandonará el servicio a partir de variables como información demográfica, servicios contratados y comportamiento de facturación.

En este trabajo se realiza un estudio comparativo de diferentes modelos de aprendizaje automático para la predicción de abandono en telecomunicaciones, utilizando el dataset *Telco Customer Churn*.

II. ESTADO DEL ARTE

El problema de predicción de abandono de clientes (*customer churn*) en el sector de telecomunicaciones ha sido ampliamente abordado mediante técnicas de *Machine Learning* bajo un enfoque de aprendizaje supervisado de clasificación binaria, donde el objetivo es estimar la probabilidad de que un

Los resultados muestran que el modelo MLP alcanza un desempeño superior, con valores de *accuracy* cercanos al 96%, evidenciando la capacidad de las redes neuronales para modelar relaciones no lineales en los datos.

Por otro lado, Saleh y Abd-Alsabour [2] exploran modelos basados en árboles de decisión, específicamente Decision Tree, Random Forest y XGBoost, destacando el uso de técnicas de ensamblado (ensemble learning). En este estudio emplean métricas adicionales como el *ROC-AUC*, que mide la capacidad discriminativa del modelo y se define como el área bajo la curva ROC. Los resultados indican que XGBoost presenta el mejor desempeño con altos valores de *accuracy* y *AUC*, superando a los modelos individuales. Este hallazgo coincide con otros estudios, que muestran que modelos como XGBoost o AdaBoost suelen funcionar mejor cuando se aplican a datos nuevos.

De forma similar Jeyapraakash y Sashi Rekha [3] comparan el desempeño de KNN con el método de ensamblado AdaBoost, utilizando principalmente la métrica de *accuracy*, definida como:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2)$$

Los resultados muestran una mejora significativa al utilizar AdaBoost, cercana al 90%, frente a KNN, cercana al 75%, lo que evidencia la efectividad de los métodos de ensamblado

para mejorar clasificadores base. Sin embargo se recalcó que esto presenta limitaciones metodológicas pues no emplean validación cruzada ni múltiples métricas de evaluación.

Por último, Omari et al. [4] proponen un enfoque de analítica predictiva basado en modelos tradicionales como Logistic Regression, Decision Trees y Random Forest. El estudio utiliza métricas estándar (*accuracy*, *precision*, *recall*, *F1-score*) y resaltan la importancia de variables como el tiempo de permanencia de los clientes, el tipo de contrato y los cargos mensuales en la predicción del abandono del servicio. Los resultados muestran que los modelos de ensamblado, particularmente Random Forest, ofrecen un mejor desempeño además de proporcionar interpretabilidad en la toma de decisiones.

En conjunto, estos trabajos evidencian que el problema de abandono de los servicios en telecomunicaciones es abordado principalmente mediante aprendizaje supervisado, con una ventaja de los modelos de ensamblado (XGBoost, Random Forest, AdaBoost) en términos de desempeño. De forma similar, aunque los modelos de deep learning como MLP pueden alcanzar niveles altos de precisión, su superioridad no es total y dependen del preprocesamiento y ajuste de hiperparámetros. Por último, se destaca la importancia de utilizar métricas más robustas como F1-Score y ROC-AUC, principalmente en problemas con desbalance de clases, donde accuracy puede ser insuficiente.

REFERENCES

- [1] R. Rabih, W. Sun, M. Ayoubi, and K. W. Jamal, "Highly Accurate Customer Churn Prediction in the Telecommunications Industry Using MLP," *International Journal of Integrated Science and Technology*, 2024.
- [2] M. E. Saleh and N. Abd-ElSabour, "Improved Decision Tree, Random Forest, and XGBoost Algorithms for Predicting Client Churn in the Telecommunications Industry," *International Journal of Advanced Computer Science and Applications*, 2024.
- [3] P. Jeyapraakash and S. Rekha, "Accuracy Measure of Customer Churn Prediction in Telecom Industry using Adaboost over K Nearest Neighbor Algorithm," *Journal of Pharmaceutical Negative Results*, 2022.
- [4] A. Omari, O. Al-Omari, T. Al-Omari, and S. M. Fati, "A Predictive Analytics Approach to Improve Telecom's Customer Retention," *Journal*, 2023.